

UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS
(Universidad decana de América)

“Año de la Esperanza y el Fortalecimiento de la Democracia”

**FACULTAD DE CIENCIAS MATEMÁTICAS,
COMPUTACIÓN CIENTÍFICA**



**COMPUTACIÓN NEUROMÓRFICA: DEL CEREBRO AL
SILICIO**

CURSO: ALGORÍTMICA Y FUNDAMENTOS DE
PROGRAMACIÓN

PROESOR: Benito Pacheco, Oscar

INTEGRANTES:

Chipani Accilio, Sara

1. Introducción

La computación neuromórfica surge como una respuesta a varias limitaciones de la computación tradicional, sobre todo cuando hablamos de inteligencia artificial y de sistemas que necesitan funcionar con poco consumo energético. El problema principal está en la separación entre memoria y procesamiento, algo que obliga a mover datos constantemente y termina encareciendo el costo energético. Frente a eso, la computación neuromórfica propone una forma de trabajar más parecida a la del cerebro, con procesamiento distribuido, paralelo y orientado a eventos.

Este enfoque se ha vuelto más interesante en los últimos años porque la IA ya no vive solo en centros de datos. Hoy también aparece en robots, sensores, dispositivos médicos, cámaras inteligentes e incluso en sistemas de IoT que tienen que decidir rápido y con energía limitada. En ese contexto, la computación neuromórfica no suena como una idea futurista lejana, sino como una alternativa bastante razonable para ciertas tareas donde la eficiencia importa tanto como la precisión.

Más que reemplazar por completo a la computación actual, este campo busca resolver problemas concretos que hoy son difíciles de manejar con CPUs y GPUs convencionales. Por eso vale la pena estudiarlo con calma: no solo por su inspiración biológica, sino porque ya hay hardware, aplicaciones y líneas de investigación que muestran resultados reales.

2. Marco conceptual

La computación neuromórfica es un paradigma de diseño de hardware y algoritmos inspirado en el sistema nervioso biológico. Su objetivo es imitar, de forma aproximada, cómo el cerebro procesa información mediante neuronas, sinapsis y conexiones distribuidas. A diferencia de la computación clásica, aquí la idea no es mover datos de un lado a otro todo el tiempo, sino organizar el sistema para que el procesamiento y la memoria estén mucho más integrados.

Las neuronas artificiales son la base de este enfoque. En muchos casos se usa el modelo *Leaky Integrate-and-Fire*, en el que una neurona acumula señales de entrada y solo dispara una salida cuando alcanza cierto umbral. No es una copia exacta de una neurona biológica, pero sí una forma bastante útil de representar comportamiento neuronal con hardware más simple y eficiente.

Las sinapsis cumplen el papel de conectar neuronas y almacenar la fuerza de esas conexiones. En los sistemas neuromórficos, pueden ser plásticas, es decir, capaces de cambiar con la actividad del sistema. Esa plasticidad es importante porque abre la puerta al aprendizaje local y a la adaptación sin necesidad de depender tanto de entrenamiento externo masivo.

Las redes neuronales de picos, o SNNs, trabajan con eventos discretos. La información no se transmite de manera continua como en una red neuronal tradicional, sino en forma de picos que aparecen solo cuando hay actividad relevante. Eso hace que el sistema pueda ser más eficiente en escenarios donde los datos no llegan todo el tiempo o donde la información útil aparece por momentos.

3. Cómo evolucionó

Aunque hoy el tema parece muy actual, sus raíces vienen de hace varias décadas. Uno de los nombres clave es Carver Mead, que propuso aprovechar las propiedades físicas de los transistores para construir circuitos inspirados en procesos biológicos. Esa idea fue importante porque cambió la pregunta: en vez de insistir solo en más velocidad, se empezó a pensar en eficiencia y paralelismo.

Durante bastante tiempo, el campo avanzó lentamente. La razón es sencilla: la computación digital tradicional siguió mejorando y resolviendo buena parte de los problemas prácticos. Pero con el crecimiento de la IA, el gasto energético y la necesidad de sistemas más especializados, la computación neuromórfica volvió a ganar fuerza. Hoy ya no se ve como una curiosidad de laboratorio, sino como una línea seria de desarrollo.

El artículo *Neuromorphic computing at scale* insiste justamente en eso: el siguiente paso ya no es solo demostrar que la idea funciona, sino lograr sistemas grandes, útiles y realmente escalables. Y ahí está lo interesante del campo, porque ya no se habla solo de inspiración biológica, sino de cómo llevarla a una infraestructura tecnológica más robusta.

4. Materiales y dispositivos

Una de las partes más llamativas de este campo es que no depende de una sola tecnología. El artículo sobre *Reconfigurable Neuromorphic Computing* muestra que hay varias rutas físicas posibles, como migración iónica, migración de portadores, transición de fase, espintrónica y fotónica. Cada una ofrece ventajas distintas y abre posibilidades diferentes para construir hardware neuromórfico.

Los memristores son especialmente importantes porque pueden representar memoria y comportamiento sináptico en un solo dispositivo. Eso los hace atractivos para crear sistemas compactos y con bajo consumo. No es casualidad que aparezcan tanto en la literatura neuromórfica: encajan muy bien con la idea de un hardware que no solo compute, sino que también conserve y adapte información.

La reconfigurabilidad también merece atención. La idea de que un mismo dispositivo pueda cambiar de función según las necesidades del sistema es una de las cosas que más empujan el campo hacia adelante. En lugar de diseñar hardware rígido para una sola tarea, se busca que el dispositivo pueda actuar como neurona, sinapsis o incluso elemento lógico dependiendo del contexto.

A eso se suman otras rutas como la espintrónica y la fotónica. La fotónica puede ayudar en interconexiones de alta velocidad, mientras que la espintrónica ofrece una forma distinta de representar estados y procesar información. No son soluciones cerradas ni completamente maduras, pero sí muestran que la computación neuromórfica todavía tiene margen para crecer desde varios frentes al mismo tiempo.

5. Sistemas representativos

Dentro de los sistemas más conocidos está **TrueNorth**, de IBM. Su importancia no está solo en su tamaño, sino en que demostró que es posible construir un chip neuromórfico digital con operación asíncrona y consumo muy bajo. Eso lo convirtió en un punto de referencia para quienes querían pasar de la teoría a una implementación real.

También destaca **SpiNNaker**, desarrollado para simular redes neuronales grandes en tiempo real. Esta plataforma es interesante porque no sigue exactamente el mismo camino que otros chips neuromórficos, sino que usa una arquitectura paralela de procesadores para modelar sistemas neuronales complejos. En cierto modo, sirve como puente entre la neurociencia y la ingeniería.

Loihi 2, de Intel, apunta mucho al aprendizaje en el propio chip. Esa parte es clave porque uno de los grandes atractivos del neuromorfismo es que no solo imita estructuras biológicas, sino también ciertas formas de adaptación. Si un sistema puede aprender localmente y responder a cambios sin tanto entrenamiento externo, entonces tiene mucho sentido para aplicaciones dinámicas.

Por su parte, **BrainScaleS** explora circuitos analógicos que operan a velocidades muy superiores a las biológicas. Eso permite acelerar experimentos y estudiar dinámica neuronal de una manera muy útil para investigación. Lo interesante de estos sistemas es que no compiten entre sí de forma directa; más bien muestran distintas formas de acercarse a una misma meta.

6. Aplicaciones reales

La robótica es uno de los campos donde la computación neuromórfica más sentido tiene. El artículo de *Science Robotics* muestra que este tipo de hardware encaja bien en tareas donde se necesita reacción rápida, eficiencia energética y procesamiento en tiempo real. En robots autónomos, eso puede marcar bastante diferencia, sobre todo cuando el sistema debe interactuar con un entorno cambiante.

La visión artificial basada en eventos es otra aplicación muy fuerte. En lugar de capturar cuadros completos a intervalos fijos, los sensores de evento registran cambios en la escena. Eso reduce el flujo de datos y hace posible una respuesta mucho más rápida, algo especialmente útil en drones, vehículos autónomos y vigilancia inteligente.

También hay aplicaciones prometedoras en salud y dispositivos biomédicos. El interés aquí tiene sentido porque muchos de estos sistemas necesitan funcionar con poca energía y con procesamiento local, sin depender siempre de una conexión externa. El artículo de aplicaciones recientes deja ver que el área ya no está limitada al laboratorio, sino que empieza a tocar problemas prácticos muy concretos.

En edge computing e IoT, la ventaja es bastante clara: decidir cerca del dato, con menos latencia y menos gasto energético, ya que no siempre se necesita una respuesta exacta en términos tradicionales, sino una decisión rápida, eficiente y suficientemente buena para operar en el mundo real.

7. Retos y limitaciones

Ya que el campo todavía no está resuelto ni explorado. Uno de los grandes problemas sigue siendo la escalabilidad. Lograr que estos sistemas crezcan sin perder estabilidad, eficiencia o reproducibilidad no es sencillo. El trabajo de *Neuromorphic computing at scale* deja claro que ese es uno de los pasos más importantes para que el campo realmente compita con otras tecnologías.

La parte de materiales también trae sus propias dificultades. Aunque los memristores y otros dispositivos emergentes son prometedores, todavía hay retos en uniformidad, integración y comportamiento consistente. El artículo sobre reconfigurabilidad muestra que hay mucho potencial, pero también bastante trabajo pendiente para que estas ideas se conviertan en soluciones confiables y no solo en prototipos interesantes.

Otro punto importante es el software. Hoy no existe un ecosistema tan fácil de usar como el de la IA convencional. Eso hace que muchos desarrolladores no puedan entrar al área con la misma comodidad con la que trabajan en TensorFlow o PyTorch. Mientras esa brecha siga ahí, la adopción masiva va a avanzar más lento de lo que podría.

También hay que considerar que convertir redes profundas tradicionales en redes de picos no siempre sale perfecto. IBM advierte que ese proceso puede afectar la precisión, así que no basta con “pasar” un modelo a neuromórfico sin más. Hay que ajustar, probar y optimizar bastante para que el resultado valga la pena.

8. Conclusión

La computación neuromórfica me parece una de las líneas más prometedoras dentro de la inteligencia artificial actual. No porque vaya a reemplazar todo lo que ya existe, sino porque ofrece una respuesta muy convincente a problemas reales: consumo energético alto, dependencia de la nube, latencia y necesidad de procesar información cerca del dispositivo.

Además, ya no estamos hablando solo de teoría. Distintas fuentes muestran que hay hardware real, materiales en desarrollo, plataformas de gran escala y aplicaciones que empiezan a tener sentido fuera del laboratorio. Eso le da al campo un peso distinto, porque demuestra que no es solo una inspiración del cerebro, sino una dirección tecnológica con posibilidades concretas.

En mi opinión, el mayor valor de esta tecnología está en que puede complementar muy bien a la computación tradicional. Las CPUs y GPUs seguirán siendo esenciales para muchas tareas, pero la computación neuromórfica puede convertirse en la mejor opción para sistemas que necesiten autonomía, rapidez y eficiencia energética. Y que, si sigue madurando, va a ocupar un lugar importante en la próxima generación de IA.

9. Bibliografía

- Ahmadi, A., Gomar, S., & Ahmadi, M. (2024). Editorial: From theory to practice: the latest developments in neuromorphic computing applications. *Frontiers in Neuroscience*, 18.
- Furber, S. (2016). Large-scale neuromorphic computing systems. *Journal of Neural Engineering*, 13(5).
- Gentili, P. L., Karg, S., Csaba, G., & Szaciłowski, K. (2024). Editorial: Reviews and perspectives in neuromorphic engineering: novel neuromorphic computing approaches. *Frontiers in Neuroscience*, 18.
- Kudithipudi, D., Schuman, C., Vineyard, C. M., Pandit, T., et al. (2025). Neuromorphic computing at scale. *Nature*, 631.
- Sandamirskaya, Y., Kaboli, M., Conradt, J., & Celişkel, T. (2022). Neuromorphic computing hardware and neural architectures for robotics. *Science Robotics*, 7(67).
- Villarreal Cobeña, A., Mendoza Villamar, R., Alay Cruz, M., & Cedeño Bravo, W. (2025). Computación neuromórfica en dispositivos IoT: un salto de eficiencia para la IA perimetral. *Revista TSE'DE*, 8(2).
- Xu, M., Chen, X., Guo, Y., Wang, Y., et al. (2023). Reconfigurable Neuromorphic Computing: Materials, Devices, and Integration. *Advanced Materials*, 35(51).