

UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS
(Universidad decana de América)

“Año de la Esperanza y el Fortalecimiento de la Democracia”

**FACULTAD DE CIENCIAS MATEMÁTICAS,
COMPUTACIÓN CIENTÍFICA**



**INFORME DE LITERATURA SOBRE COMPUTACIÓN
NEUROMÓRFICA**

CURSO: ALGORÍTMICA Y FUNDAMENTOS DE PROGRAMACIÓN

PROESOR: Benito Pacheco, Oscar

ALUMNA: Chipani Accilio, Sara

2026

1. Introducción

La computación neuromórfica es un paradigma de diseño de hardware y algoritmos inspirado en los principios de procesamiento del cerebro biológico. A diferencia de la arquitectura clásica de von Neumann, que separa memoria y procesamiento, los sistemas neuromórficos buscan la co-localización de memoria y cómputo, la comunicación basada en eventos (picos o "spikes") y el procesamiento paralelo y de bajo consumo energético. Este informe analiza siete artículos científicos recientes que abordan el tema desde ángulos complementarios: revisiones sistemáticas de aplicaciones en IoT, editoriales de investigación sobre avances teóricos y prácticos, artículos de referencia sobre hardware para robótica, sistemas neuromórficos a gran escala, el estado del arte y los retos de escalabilidad, materiales y dispositivos reconfigurables, y perspectivas sobre enfoques no convencionales de computación neuromórfica.

Artículo 1. Computación neuromórfica en dispositivos IoT: un salto de eficiencia para la IA perimetral

Autores: Villarreal Cobeña, Mendoza Villamar, Alay Cruz y Cedeño Bravo

Fuente: Revista TSE'DE (ISSN 2600-5557) **Año:** 2025

Objetivo y metodología.

Se trata de una revisión sistemática de la literatura que analiza 50 estudios publicados entre 2020 y 2025, extraídos de bases como IEEE Xplore, ScienceDirect, arXiv, Google Scholar, SciELO y Redalyc. El propósito es evaluar cómo la computación neuromórfica optimiza la eficiencia energética y reduce la latencia en dispositivos IoT para aplicaciones de IA perimetral (edge AI).

Hallazgos principales.

- Los chips neuromórficos (p. ej. Loihi) pueden reducir el consumo energético hasta 16 veces en tareas de procesamiento de secuencias frente al hardware tradicional.
- La memoria analógica in-memory computing (AIMC) permite reducciones de latencia de hasta 10 veces en tareas como la detección de anomalías.
- Las redes neuronales de picos (SNN) procesan datos de forma asíncrona y basada en eventos, evitando el cuello de botella energético de la arquitectura von Neumann.
- Las aplicaciones más beneficiadas son el monitoreo médico y ambiental, las ciudades inteligentes y la detección de anomalías en redes IoT.

Limitaciones señaladas.

La escalabilidad limitada, la falta de estandarización y de benchmarks comunes, y el alto costo y complejidad de fabricación del hardware neuromórfico dificultan una adopción masiva. El mercado proyectado alcanzaría 47 300 millones de dólares hacia 2034.

Artículo 2. From Theory to Practice: the latest developments in neuromorphic computing applications

Autores: Ahmadi, Gomar y Ahmadi

Fuente: Frontiers in Neuroscience **Año:** 2024

Objetivo.

Este editorial presenta un número temático de la revista dedicado a tender un puente entre los avances teóricos y las aplicaciones prácticas de la computación neuromórfica, reuniendo cuatro contribuciones originales sobre hardware, arquitecturas y aplicaciones.

Contribuciones destacadas del número temático.

- Un marco de simulación (SHIP) para validar nuevas tecnologías de redes neuronales de picos en hardware antes de su implementación física.
- Una revisión de las tendencias en sinapsis artificiales y sistemas neuromórficos, considerando efectos no ideales del hardware real.
- Un estudio sobre el "silencio neuronal" como estrategia para mejorar el rendimiento y la eficiencia energética de las redes de picos.
- Una demostración de ejecución en tiempo real de modelos SNN con plasticidad sináptica para el reconocimiento de dígitos manuscritos sobre hardware SIMD.

Mensaje central.

Los editores subrayan que, aunque la computación neuromórfica promete resolver los problemas de consumo energético y escalabilidad de la IA convencional gracias al paralelismo inherente y al procesamiento basado en eventos, persisten retos de escalabilidad, fiabilidad, integración con tecnologías existentes y la falta de benchmarks estandarizados.

Artículo 3. Neuromorphic computing hardware and neural architectures for robotics

Autores: Sandamirskaya, Kaboli, Conradt y Celikel

Fuente: Science Robotics **Año:** 2022

Objetivo.

Este artículo de perspectiva examina cómo el hardware neuromórfico —eficiente, rápido y de bajo consumo— puede resolver las estrictas exigencias de potencia, latencia y adaptabilidad de las tareas robóticas, y revisa aplicaciones ya demostradas en robótica.

Principios de hardware neuromórfico.

Los autores describen los principios biológicos clave replicados en el hardware: ausencia de separación entre memoria y procesamiento, representación distribuida de variables, dinámicas temporales inherentes (picos asíncronos) y comunicación dirigida por eventos, lo que reduce drásticamente el consumo energético frente al cómputo síncrono convencional.

Aplicaciones en robótica revisadas.

- Localización y mapeo simultáneos (SLAM): implementaciones en el chip Loihi logran hasta 100 veces menor consumo dinámico de potencia que una CPU convencional.
- Aprendizaje rápido y en línea de patrones visuales, táctiles y olfativos, aprovechando la plasticidad sináptica siempre activa del hardware neuromórfico.
- Control de movimiento: controladores PID adaptativos y optimización de trayectorias implementados en redes de picos, con reducción de la carga computacional.
- Integración de visión basada en eventos con control motor, alcanzando tasas de control de hasta 20 kHz con latencias inferiores a 5 ms.

Retos abiertos.

Los autores señalan la falta de herramientas para depurar redes de picos, la escasez de conjuntos de datos y tareas compartidas para comparar sistemas, y la ausencia de estándares de interfaz con sensores y actuadores convencionales como los principales obstáculos para la robótica neuromórfica.

Artículo 4. Large-Scale Neuromorphic Computing Systems

Autores: Steve Furber

Fuente: Journal of Neural Engineering **Año:** 2016

Objetivo.

Esta revisión temática presenta una breve historia de la ingeniería neuromórfica (desde los trabajos de Carver Mead en los años 80) y compara en profundidad cuatro de los primeros sistemas neuromórficos a gran escala: IBM TrueNorth, Stanford Neurogrid, BrainScaleS (Heidelberg) y SpiNNaker (Manchester).

Comparación de los cuatro sistemas.

- **IBM TrueNorth:** chip totalmente digital con 1 millón de neuronas y 256 millones de sinapsis por placa de 16 chips; orientado a aplicaciones cognitivas de muy bajo consumo (~70 mW).
- **Stanford Neurogrid:** circuitos analógicos de subumbral en tiempo real biológico, con comunicación digital de picos; adecuado para control robótico.
- **BrainScaleS:** circuitos analógicos de sobreumbral a escala de oblea de silicio, que funcionan 10 000 veces más rápido que el tiempo real biológico, ideales para estudiar el aprendizaje a largo plazo.
- **SpiNNaker:** sistema digital multinúcleo (hasta 1 millón de núcleos ARM) que ejecuta modelos neuronales en software, ofreciendo la mayor flexibilidad de programación entre los cuatro sistemas.

Conclusión del autor.

No existe un enfoque único superior: cada sistema representa un compromiso distinto entre eficiencia energética, densidad de integración, flexibilidad de programación y velocidad de simulación. El artículo anticipa la necesidad de sistemas de próxima generación guiados por la experiencia de usuario acumulada con esta primera generación.

Artículo 5. Neuromorphic computing at scale

Autores: Kudithipudi, Schuman, Vineyard, Pandit, Merkel, Furber y otros (18 autores, múltiples instituciones)

Fuente: Nature, vol. 637 **Año:** 2025

Objetivo.

Este extenso artículo de revisión evalúa el estado actual y el camino hacia sistemas neuromórficos "a escala" —capaces de resolver tareas reales complejas—, identificando las características clave necesarias, los retos del ecosistema de software/hardware y una hoja de ruta de preguntas de investigación a corto, medio y largo plazo.

Características clave para la escalabilidad.

- Estructura distribuida y jerárquica, similar a la organización de la corteza visual.
- Dispersión (sparsity) en actividad y conectividad, inspirada en el desarrollo sináptico del cerebro.
- Escalabilidad neuronal: soporte de grandes cantidades de neuronas por chip o sistema.
- Comunicación asíncrona basada en eventos y reconfigurabilidad dinámica de la red.
- Redundancia, interfaces de sensores/actuadores optimizadas y "conciencia" de los recursos energéticos y de memoria disponibles.

Brechas identificadas en el ecosistema de software.

Los autores comparan el ecosistema de IA convencional (con formatos estándar como ONNX y compiladores maduros como TensorRT) con el ecosistema neuromórfico, mucho más fragmentado: faltan formatos de intercambio de topologías neuronales de alto nivel, optimizadores de inferencia para despliegue a gran escala y herramientas de compilación cruzada entre plataformas (Loihi, SpiNNaker, etc.).

Perspectivas destacadas.

El trabajo compara la situación actual con el "momento AlexNet" del aprendizaje profundo, sugiriendo que la computación neuromórfica podría estar cerca de un avance similar si se resuelven los cuellos de botella de hardware y software. También destaca aplicaciones emergentes en simulación neurocientífica a escala cerebral, dispositivos de memoria emergentes (RRAM, memristores) y la necesidad de bancos de pruebas abiertos y compartidos.

Artículo 6. Reconfigurable Neuromorphic Computing: Materials, Devices, and Integration

Autores: Xu, Chen, Guo, Wang, Qiu, Du, Cui, Wang y Xiong

Fuente: Advanced Materials **Año:** 2023

Objetivo.

Esta extensa revisión examina la computación neuromórfica reconfigurable —dispositivos capaces de cambiar de función bajo demanda (sinapsis, neurona, memoria, lógica)— desde tres niveles: materiales/dispositivo, arreglo (array) e integración de sistemas.

Mecanismos de reconfigurabilidad revisados.

- **Migración iónica** (cationes, aniones, dopaje electroquímico): dispositivos de metalización electroquímica (ECM) que alternan entre modo sináptico no volátil y modo neuronal volátil.
- **Migración de portadores de carga:** modulación eléctrica, óptica y por compuerta ferroeléctrica de transistores 2D (WSe₂, MoS₂, grafeno) para sinapsis excitatorias e inhibitorias reconfigurables.
- **Transición de fase:** uniones túnel ferroeléctricas, materiales de cambio de fase amorfo-cristalino (GST), transición metal-aislante (Mott) y superconductividad (uniones Josephson, nanocables superconductores).
- **Espintrónica:** uniones de tunelaje magnético, pares de torque de espín-órbita, paredes de dominio, skyrmions y hielo de espín artificial (ASI).
- **Fotónica:** sinapsis y neuronas ópticas basadas en multiplexación por longitud de onda (WDM), materiales de cambio de fase fotónicos y redes difractivas.

Integración a nivel de sistema.

Se describen implementaciones basadas en CMOS (FPGA, TrueNorth, Loihi, Tianjic) y basadas en memoria resistiva (ReRAM), como el chip NeuRRAM, que logra una precisión de inferencia comparable al software con hasta 48 núcleos de cómputo en memoria reconfigurables, así como arquitecturas heterogéneas apiladas en 3D con interconexión óptica sin cables.

Retos futuros identificados por los autores.

- Lograr una integración funcional más potente y comprensiva de componentes inspirados en el cerebro.
- Desarrollar conmutación robusta, reproducible y de alta resistencia (endurance) entre estados.
- Incorporar capacidad de autoadaptación ("grow-when-required") para tareas en entornos cambiantes.

Artículo 7. Reviews and perspectives in neuromorphic engineering: novel neuromorphic computing approaches (Editorial)

Autores: Gentili, Karg, Csaba y Szaciłowski

Fuente: Frontiers in Neuroscience **Año:** 2024

Objetivo.

Este editorial enmarca la computación neuromórfica dentro de la "Computación Natural", una estrategia interdisciplinaria para abordar la complejidad computacional de problemas intratables (por ejemplo, el plegamiento de proteínas o el problema del viajante), inspirándose en la naturaleza para crear nuevos algoritmos, materiales y arquitecturas de cómputo. Presenta siete contribuciones de un número temático.

Enfoques no convencionales destacados.

- **Redes neuronales oscilatorias (ONN):** el cómputo se basa en la dinámica de sincronización de osciladores acoplados; se muestra que el algoritmo de retropropagación a través del tiempo mejora su capacidad de reconocimiento de patrones, y se demuestran reglas de aprendizaje no supervisado (Hebbiana, Storkey) compatibles con el aprendizaje en el propio chip.
- **Materiales de cambio de fase (VO2):** osciladores de relajación de bajo consumo basados en la transición metal-aislante del dióxido de vanadio, implementados en tecnología CMOS comercial.
- **Memristores de grafeno (RRAM):** dispositivos con mayor velocidad de conmutación, retención y estabilidad química, capaces de ofrecer más de dos estados para cómputo analógico.
- **Fotónica y electrónica co-integradas:** se argumenta que el enfoque optoelectrónico es clave para alcanzar el ancho de banda de interconexión necesario para modelar redes neuronales a escala biológica.
- **Computación neuromórfica "en húmedo" (wetware):** tres estrategias basadas en soluciones líquidas —redes de reacciones químicas, biología sintética (ADN, ARN, proteínas) e iontrónica nanofluídica— que emulan redes neuronales mediante señales electroquímicas y ópticas.

Mensaje central.

Los editores concluyen que combinar simultáneamente nuevos algoritmos, materiales y arquitecturas es una tarea compleja, pero probablemente la vía más prometedora para que la computación neuromórfica supere a la inteligencia artificial convencional en eficiencia energética y capacidad de abordar sistemas complejos.

2. Síntesis comparativa y tendencias comunes

2.1 Motivación común: eficiencia energética y el cuello de botella de von Neumann

Los siete artículos coinciden en identificar el mismo problema de partida: la separación entre memoria y procesamiento en la arquitectura von Neumann convencional genera un consumo energético y una latencia inaceptables para aplicaciones de IA en tiempo real, especialmente en dispositivos con recursos limitados (IoT, robots móviles, prótesis). La co-localización de memoria y cómputo, y el procesamiento disperso basado en eventos, son la respuesta compartida en todos los trabajos.

2.2 Evolución histórica del hardware

Al leer los artículos 4 y 5 en conjunto se aprecia una clara línea evolutiva: el trabajo de Furber (2016) documenta la primera generación de sistemas a gran escala (TrueNorth, Neurogrid, BrainScaleS, SpiNNaker, del orden de 1 millón de neuronas), mientras que la revisión de Kudithipudi et al. (2025) en Nature muestra que los sistemas actuales (Loihi 2, SpiNNaker2, memristores RRAM) ya superan los 1000 millones de neuronas simuladas, y proyecta sistemas de más de 10 000 millones de neuronas para 2026.

2.3 De dispositivos fijos a dispositivos reconfigurables

El artículo 6 (Xu et al.) representa un salto conceptual respecto a los artículos 3 y 4: en lugar de diseñar un dispositivo fijo para una función neuronal o sináptica específica, propone dispositivos que pueden reconfigurarse bajo demanda para actuar como neurona, sinapsis, memoria o puerta lógica, aumentando la funcionalidad sin aumentar la complejidad física del chip.

2.4 De lo puramente electrónico a enfoques híbridos y no convencionales

Mientras los artículos 3, 4 y 5 se centran en hardware digital o analógico basado en silicio, los artículos 6 y 7 amplían el panorama hacia la espintrónica, la fotónica, la superconductividad y hasta la "computación en húmedo" basada en reacciones químicas y biología sintética, lo que sugiere que el campo está diversificando activamente sus sustratos físicos de cómputo.

2.5 Aplicaciones y sectores beneficiados

Existe consenso en las aplicaciones objetivo: monitoreo médico y ambiental, ciudades inteligentes, vehículos autónomos y drones, robótica (SLAM, control motor, visión), y detección de anomalías en redes IoT. El artículo 1 cuantifica el mercado proyectado en 47 300 millones de dólares para 2034, cifra coherente con la proyección de 556,6 millones de dólares en chips neuromórficos para 2026 citada en el artículo 5.

2.6 Retos persistentes señalados en todos los artículos

- **Falta de estandarización:** ausencia de formatos de intercambio y benchmarks comunes (artículos 1, 3 y 5).
- **Brecha de software:** herramientas de programación de alto nivel inmaduras en comparación con el ecosistema de aprendizaje profundo (artículos 2 y 5).
- **Escalabilidad y costo de fabricación:** complejidad y costo del hardware neuromórfico, especialmente en materiales emergentes (artículos 1 y 6).
- **Robustez y variabilidad:** baja resistencia a ciclos (endurance) y variabilidad dispositivo a dispositivo en tecnologías reconfigurables (artículo 6).

3. Conclusiones

El conjunto de artículos analizados traza un panorama coherente de la computación neuromórfica como campo en plena maduración: nació de la inspiración biológica de imitar al cerebro, evolucionó hacia arquitecturas específicas para robótica y aplicaciones IoT/edge, y hoy enfrenta el reto de escalar a sistemas capaces de resolver problemas del mundo real, apoyándose en nuevos materiales y dispositivos reconfigurables y en enfoques físicos alternativos —espintrónica, fotónica, química— que amplían el concepto más allá de la electrónica de silicio. El consenso más sólido entre los siete trabajos es que la eficiencia energética y el procesamiento basado en eventos son las ventajas centrales del paradigma, mientras que la estandarización del software, la robustez del hardware y la existencia de bancos de pruebas compartidos son las principales barreras que deben superarse para que la computación neuromórfica alcance un impacto comparable al que tuvo el aprendizaje profundo en la última década.

4. Referencias de los artículos analizados

- Ahmadi, A., Gomar, S., & Ahmadi, M. (2024). Editorial: From theory to practice: the latest developments in neuromorphic computing applications. *Frontiers in Neuroscience*, 18.
- Furber, S. (2016). Large-scale neuromorphic computing systems. *Journal of Neural Engineering*, 13(5).
- Gentili, P. L., Karg, S., Csaba, G., & Szaciłowski, K. (2024). Editorial: Reviews and perspectives in neuromorphic engineering: novel neuromorphic computing approaches. *Frontiers in Neuroscience*, 18.
- Kudithipudi, D., Schuman, C., Vineyard, C. M., Pandit, T., et al. (2025). Neuromorphic computing at scale. *Nature*, 631.
- Sandamirskaya, Y., Kaboli, M., Conradt, J., & Celikel, T. (2022). Neuromorphic computing hardware and neural architectures for robotics. *Science Robotics*, 7(67).
- Villarreal Cobeña, A., Mendoza Villamar, R., Alay Cruz, M., & Cedeño Bravo, W. (2025). Computación neuromórfica en dispositivos IoT: un salto de eficiencia para la IA perimetral. *Revista TSE'DE*, 8(2).
- Xu, M., Chen, X., Guo, Y., Wang, Y., et al. (2023). Reconfigurable Neuromorphic Computing: Materials, Devices, and Integration. *Advanced Materials*, 35(51).